

Rapport Scientifique sur la Prédiction de la Centralité dans le Réseau Social Pokec via des Modèles GNN

ATRAOUI Yasmine P2029383

BOUHOUC Roua P1701600

RAVELOSON Maherinirina P2003422

1. Introduction

L'analyse des réseaux sociaux à grande échelle, tels que le réseau slovaque Pokec, offre une opportunité unique de comprendre les dynamiques complexes qui régissent les interactions humaines. Au cœur de cette analyse se trouve le concept de **centralité**, une mesure qui quantifie l'importance ou l'influence d'un individu (un nœud) au sein de la structure globale du réseau. Comprendre les facteurs qui déterminent la centralité d'un utilisateur est essentiel pour des applications allant de la détection d'influenceurs à la modélisation de la propagation de l'information.

La problématique centrale de cette étude est de déterminer s'il est possible de **prédire la centralité d'un utilisateur** en se basant sur une combinaison de ses attributs démographiques et de sa position topologique dans le graphe social. Pour ce faire, nous explorons l'efficacité des Réseaux de Neurones sur Graphes (GNNs), une classe de modèles d'apprentissage automatique de pointe spécifiquement conçus pour traiter des données structurées en graphe.

Ce rapport présente une analyse comparative rigoureuse de deux approches expérimentales, documentées dans les carnets de notes projet-12 (approche initiale) et projet-12-1-merged (approche corrigée et approfondie). L'objectif est d'évaluer de manière critique l'impact des choix méthodologiques – du prétraitement des données à l'architecture du modèle – sur la performance et la validité des prédictions. Cette démarche comparative met en lumière les facteurs clés de succès pour l'application des GNNs à des tâches de régression nodale sur des réseaux sociaux réels. La section suivante détaillera les étapes fondamentales de préparation des données qui constituent le socle de cette analyse.

1.1 Description et Préparation du Jeu de Données : Le Réseau Social Pokec

Cette section a pour objectif de décrire les caractéristiques fondamentales du jeu de données Pokec, un réseau social slovaque à grande échelle. Une compréhension approfondie de sa structure, de ses propriétés macroscopiques et des attributs de ses utilisateurs est un prérequis indispensable pour définir une méthodologie d'analyse robuste et interpréter correctement les résultats qui en découleront. Nous établirons ici les bases de notre analyse en détaillant la source des données, leur format, ainsi que les implications directes de leurs caractéristiques sur les choix de modélisation.

1.1.1 Source et Propriétés Macroscopiques du Réseau

Le jeu de données utilisé pour cette étude provient du *Stanford Network Analysis Project* (SNAP) et représente un instantané du réseau social en ligne le plus populaire de Slovaquie, Pokec. Ce réseau connecte plus de 1,6 million d'utilisateurs et constitue un exemple typique de graphe social à grande échelle, riche en informations structurelles et sémantiques. Les données ont été collectées par un processus de crawling entre le 25 et le 27 mai 2012.

Les propriétés macroscopiques du réseau complet permettent de saisir son échelle et sa topologie globale :

- **Taille du réseau** : Le graphe est composé de 1 632 803 nœuds (utilisateurs) et de 30 622 564 arêtes (relations d'amitié).
- **Nature des relations** : Les arêtes sont dirigées, signifiant qu'une relation d'amitié n'est pas nécessairement réciproque. Un utilisateur A peut considérer B comme un ami sans que B ne considère A comme tel.
- **Période de collecte** : Les données reflètent l'état du réseau sur une période de trois jours, du 25 au 27 mai 2012.
- **Coefficient de clustering moyen** : La valeur de 0,1094 indique la probabilité que deux amis d'un utilisateur soient également amis entre eux.
- **Diamètre** : Le plus long des plus courts chemins entre deux nœuds quelconques est de 11, et un "diamètre effectif au 90ème percentile" de 5.2 (selon Leskovec, SNAP), ce qui signifie que 90% des paires de nœuds connectés peuvent être atteintes en un peu plus de 5 sauts.

Ces métriques, combinant un diamètre effectif faible (5.2) et un coefficient de clustering non négligeable (0,1094), sont caractéristiques des graphes dits "petit monde", où la plupart des nœuds peuvent être atteints depuis n'importe quel autre nœud par un petit nombre de pas. La structure des fichiers bruts qui encodent ce réseau est détaillée ci-après.

1.1.2 Structure des Données Brutes et Profils Utilisateurs

Comprendre la structure des fichiers de données bruts est une étape cruciale pour l'ingénierie des caractéristiques et l'extraction d'informations pertinentes. Le jeu de données Pokec est distribué en deux fichiers principaux :

1. soc-pokec-relationships.txt : Ce fichier texte contient la liste des relations d'amitié. Chaque ligne est composée de deux identifiants d'utilisateurs séparés par une tabulation, indiquant un lien dirigé du premier vers le second.
2. soc-pokec-profiles.txt : Ce fichier contient les attributs démographiques et de profil des utilisateurs, également sous forme de données tabulées. Les valeurs manquantes sont explicitement marquées par la chaîne de caractères "null".

La structure du fichier de profils est particulièrement riche et offre de nombreuses variables pour l'analyse. Le tableau suivant détaille l'ensemble des colonnes disponibles.

Colonne	Description
user_id	Entier unique servant d'identifiant pour chaque utilisateur.

public	Booléen (1/0) indiquant si toutes les relations de l'utilisateur sont publiques.
completion_percentage	Entier représentant le pourcentage de complétion du profil.
gender	Booléen, où la valeur 1 correspond à un homme. La valeur 0 est interprétée comme correspondant à une femme.
region	Chaîne de caractères décrivant la région de l'utilisateur (principalement en Slovaquie, mais aussi des pays étrangers).
last_login	Date et heure de la dernière connexion de l'utilisateur.
registration	Date et heure de l'inscription de l'utilisateur.
AGE	Entier représentant l'âge de l'utilisateur. Une valeur de 0 indique que l'âge n'est pas renseigné.
body	Champ textuel libre.
I_am_working_in_field	Champ textuel libre décrivant le domaine professionnel.
spoken_languages	Champ textuel libre listant les langues parlées.
hobbies	Champ textuel libre listant les passe-temps.

l_most_enjoy_good_food	Champ textuel libre sur les préférences culinaires.
pets	Champ textuel libre décrivant les animaux de compagnie.
body_type	Champ textuel libre décrivant la morphologie.
my_eyesight	Champ textuel libre sur la vue.
eye_color	Champ textuel libre décrivant la couleur des yeux.
hair_color	Champ textuel libre décrivant la couleur des cheveux.
hair_type	Champ textuel libre décrivant le type de cheveux.
completed_level_of_education	Champ textuel libre décrivant le niveau d'éducation.
favourite_color	Champ textuel libre sur la couleur préférée.
relation_to_smoking	Champ textuel libre sur le rapport au tabagisme.
relation_to_alcohol	Champ textuel libre sur le rapport à l'alcool.
sign_in_zodiac	Champ textuel libre sur le signe du zodiaque.
on_pokec_i_am_looking_for	Champ textuel libre sur ce que l'utilisateur recherche sur le site.

love_is_for_me	Champ textuel libre décrivant la vision de l'amour.
relation_to_casual_sex	Champ textuel libre sur le rapport aux relations sexuelles occasionnelles.
my_partner_should_be	Champ textuel libre décrivant le partenaire idéal.
marital_status	Champ textuel libre décrivant le statut marital.
children	Champ textuel libre concernant les enfants.
relation_to_children	Champ textuel libre sur le rapport aux enfants.
I_like_movies	Champ textuel libre sur l'appréciation des films.
I_like_watching_movie	Champ textuel libre sur le visionnage de films.
I_like_music	Champ textuel libre sur l'appréciation de la musique.
I_mostly_like_listening_to_music	Champ textuel libre sur les genres musicaux préférés.
the_idea_of_good_evening	Champ textuel libre sur l'idée d'une bonne soirée.
I_like_specialties_from_kitchen	Champ textuel libre sur les spécialités culinaires appréciées.
fun	Champ textuel libre sur le divertissement.

I_am_going_to_concerts	Champ textuel libre sur la fréquentation des concerts.
my_active_sports	Champ textuel libre sur les sports actifs pratiqués.
my_passive_sports	Champ textuel libre sur les sports passifs suivis.
profession	Champ textuel libre sur la profession.
I_like_books	Champ textuel libre sur l'appréciation des livres.
life_style	Champ textuel libre sur le style de vie.
music	Champ textuel libre (potentiellement URL de club/groupe).
cars	Champ textuel libre (potentiellement URL de club/marque).
politics	Champ textuel libre (potentiellement URL de club/parti).
relationships	Champ textuel libre (potentiellement URL).
art_culture	Champ textuel libre (potentiellement URL).
hobbies_interests	Champ textuel libre (potentiellement URL).

science_technologies	Champ textuel libre (potentiellement URL).
computers_internet	Champ textuel libre (potentiellement URL).
education	Champ textuel libre (potentiellement URL).
sport	Champ textuel libre (potentiellement URL).
movies	Champ textuel libre (potentiellement URL).
travelling	Champ textuel libre (potentiellement URL).
health	Champ textuel libre (potentiellement URL).
companies_brands	Champ textuel libre (potentiellement URL).
more	Champ textuel libre (potentiellement URL).

Note : Le jeu de données contient 163 profils pour lesquels le completion_percentage est de 0. Il est supposé que ces profils correspondent à des comptes qui ont été supprimés ou désactivés pendant la période de collecte des données.

Cette double structure, alliant topologie du réseau et attributs nodaux, ouvre la voie à des analyses multidimensionnelles, dont les implications sont discutées dans la section suivante.

1.1.3 Caractéristiques Majeures et Implications pour l'Analyse

Les caractéristiques brutes du réseau ne sont pas de simples métriques ; elles conditionnent directement les choix méthodologiques et la portée des analyses futures. Leur examen critique est donc essentiel pour construire un protocole expérimental pertinent.

- **Nature dirigée des relations :** La structure de graphe dirigé implique que les concepts de voisinage et de centralité doivent être traités avec soin. Par exemple, le degré d'un nœud se

décompose en degré entrant (popularité) et sortant (activité). Les algorithmes choisis pour l'analyse, tels que PageRank ou certains modèles de GNN, doivent être capables de prendre en compte l'orientation des liens pour capturer correctement les flux d'information ou d'influence.

- **Faible coefficient de clustering** : La valeur de 0,1094, relativement basse pour un réseau social, suggère une structure communautaire moins marquée que dans d'autres réseaux. Les amitiés tendent à être plus diffuses plutôt que de former des groupes locaux très denses. Cette topologie peut influencer la distribution des mesures de centralité et rendre les algorithmes de détection de communautés basés sur la densité (comme Louvain) potentiellement moins efficaces ou plus difficiles à interpréter.
- **Richesse des données de profil** : La disponibilité d'attributs démographiques (âge, genre, région) et comportementaux (fumeur, buveur, etc.) est une opportunité majeure. Elle permet d'enrichir les modèles en combinant les informations structurelles du graphe avec les caractéristiques sémantiques des nœuds. Cela ouvre la voie à des questions de recherche sur l'homophilie (qui se ressemble s'assemble ?) ou sur la corrélation entre le profil d'un utilisateur et sa position dans le réseau.
- **Qualité des données** : La présence de nombreuses valeurs manquantes (null) et de profils partiellement remplis constitue un défi méthodologique. Une étape rigoureuse de nettoyage et d'imputation est indispensable, que ce soit par des approches simples comme le remplacement par la moyenne ou le mode, ou par des méthodes plus complexes visant à modéliser les valeurs manquantes. Le choix de la stratégie pour gérer ces données aura un impact direct sur la validité et la robustesse des résultats.

Pour surmonter ces défis, un protocole rigoureux d'extraction et de prétraitement est donc requis, comme détaillé dans la section suivante.

2.0 Préparation des Données et Ingénierie des Caractéristiques

Le succès de tout projet d'apprentissage automatique repose de manière critique sur la qualité de la préparation des données et de l'ingénierie des caractéristiques (*feature engineering*). Ce principe, souvent résumé par l'adage "Garbage in, Garbage out" (GIGO), est particulièrement pertinent pour les données de graphes, où les informations structurelles et attributaires sont intrinsèquement liées. Une préparation rigoureuse est donc indispensable pour garantir que le modèle puisse apprendre des signaux pertinents et non des artefacts issus d'un traitement inadéquat.

2.1 Construction du Sous-Graphe d'Étude

L'analyse reposant sur le réseau social slovaque **Pokec**, qui est un réseau social à grande échelle, a dû initialement faire face à la **nature massive** des données brutes. Le jeu de données complet se compose de **1 632 803 nœuds** et de **30 622 564 arêtes**. Dans le cadre d'une étude exploratoire et expérimentale utilisant des modèles gourmands en ressources tels que les Réseaux de Neurones sur Graphes (GNNs), une étape critique de **préparation des données** a été indispensable pour extraire un sous-graphe d'étude à la fois **représentatif et de taille gérable**. Cette rigueur est dictée par le

principe que le succès de l'apprentissage automatique repose sur la qualité de la préparation des données.


Pour garantir que le sous-graphe conserve une **structure topologique significative** et ne constitue pas un échantillon purement aléatoire qui masquerait les signaux pertinents, une méthode d'échantillonnage par **parcours en largeur (BFS) multi-graines** (*multi_seed_bfs*) a été employée.

Cette technique est mise en œuvre en lançant **plusieurs parcours en largeur (BFS)** à partir de **nœuds de départ sélectionnés aléatoirement**. L'exploration est délibérément limitée par une **profondeur maximale** (par exemple, *depth_limit=3*). Contrairement à un échantillonnage aléatoire simple, qui tend à détruire la **connectivité locale** et les **relations communautaires**, l'approche BFS multi-graines vise spécifiquement à obtenir un sous-graphe **largement connecté** et **structuré**. En effet, la détection de communautés implique la recherche de groupes de nœuds fortement connectés entre eux, une structure que cette méthode d'échantillonnage préserve mieux.

Le sous-graphe final, issu de cette procédure, a servi de base à l'ensemble des expérimentations menées. Il est composé de :

- **10 681 nœuds** (représentant les utilisateurs).
- **23 726 arêtes** (représentant les relations d'amitié).

Les propriétés structurelles de ce sous-graphe échantillonné, telles qu'une **longueur moyenne approximée du plus court chemin de 2.976** et un **diamètre approximé de 6**, confirment qu'il s'agit d'un réseau dense localement mais efficacement connecté globalement, assurant ainsi la validité des analyses topologiques subséquentes



Pokec connected subgraph

```
Nombre de nœuds : 10681
Nombre d'arêtes : 23726
Densité : 0.000416
Clustering global : 0.0016
Longueur moyenne approximée du plus court chemin : 2.976
Diamètre approximé (99.9e percentile) : 6
```

2.2 Traitement des Attributs Utilisateurs

La phase de préparation des données a débuté par une étape critique de sélection des attributs afin de générer un vecteur de caractéristiques initial pertinent et exploitable, tout en minimisant l'introduction de bruit et de redondance.

L'exclusion des nombreuses colonnes complexes, textuelles ou non structurées (telles que les hobbies, les professions, ou les descriptions corporelles) a été motivée par la nécessité d'améliorer l'efficacité du processus d'exploration et de garantir une meilleure interprétabilité des patrons qui seront découverts par la suite. Les attributs conservés, jugés directement pertinents pour modéliser le profil socio-démographique de l'utilisateur, sont les suivants : gender, age, region, smoker, drinker, et completion (pourcentage de complétion du profil).

Sur cet ensemble réduit, un nettoyage minutieux a été appliqué, incluant la simplification des champs catégoriels libres (smoker et drinker) en catégories claires ("yes", "no", "unknown"). Par ailleurs, l'application d'une standardisation Z-score aux variables numériques (age et completion) était impérative. Cette transformation garantit que toutes les caractéristiques conservées sont ramenées sur une échelle comparable, empêchant ainsi que les variables avec la plus grande amplitude (telle que le pourcentage de complétion) ne dominent indûment les calculs de distance lors de l'analyse, un risque majeur dans la plupart des algorithmes de Data Mining. Enfin, les variables catégorielles ont été préparées pour un encodage One-Hot, indispensable pour éviter que les algorithmes n'attribuent un ordre ou une distance arbitraire aux catégories nominales, ce qui conduirait à des résultats erronés.

2.3 Analyse Comparative de l'Encodage des Variables Catégorielles

Le traitement des variables catégorielles (gender, region, etc.) constitue une divergence méthodologique majeure entre les deux approches étudiées, avec un impact direct sur la performance.

Approche Initiale (projet-12)	Approche Corrigée (projet-12-1-merged)
-------------------------------	--

Utilisation de LabelEncoder : Cette méthode assigne un entier unique à chaque catégorie (ex: Bratislava→0, Kosice→1). Pour des variables nominales sans ordre intrinsèque, cette approche est méthodologiquement incorrecte. Elle introduit une relation d'ordre artificielle ($1 > 0$) que le modèle peut interpréter à tort comme un signal, biaisant ainsi l'apprentissage.	Utilisation de OneHotEncoder : Cette méthode crée une nouvelle colonne binaire (0 ou 1) pour chaque catégorie. Par exemple, une variable region avec 10 catégories est transformée en 10 nouvelles caractéristiques. C'est l'approche méthodologiquement correcte car elle représente les catégories comme des entités indépendantes, sans introduire de relation ordinale fallacieuse.
---	--

Le choix de la méthode d'encodage n'est pas un détail technique mineur ; il est fondamental pour la validité sémantique des données fournies au modèle et, comme les résultats le montreront, pour sa capacité à apprendre des relations significatives. C'est pourquoi, à l'issue de cette phase de préparation, nous avons retenu l'encodage One-Hot pour la suite de l'analyse.

2.4 Ingénierie des Caractéristiques Topologiques

Afin d'optimiser la modélisation et la prédiction au sein du réseau, le vecteur de caractéristiques initial de chaque nœud a été enrichi par l'adjonction d'informations quantifiant sa position et son rôle intrinsèque dans la topologie du graphe. Cette stratégie d'ingénierie des caractéristiques vise à fournir au modèle une connaissance explicite de la structure.

Plus précisément, les indicateurs structurels suivants ont été calculés et ajoutés à la matrice d'entrée :

- la centralité de degré normalisée (deg_norm)
- le coefficient de regroupement (clust)
- le numéro de cœur standardisé (core_z)
- le PageRank standardisé (pr_z)

L'intégration de ces métriques de centralité et de structure est cruciale, car elle permet d'éviter que le modèle ne doive déduire implicitement ces informations uniquement par le mécanisme de propagation des messages (message passing) inhérent aux modèles d'apprentissage sur graphes (GNN). Bien que la propagation d'information entre les nœuds soit fondamentale pour l'apprentissage sur graphes, le fait d'inclure des mesures de la topologie locale et globale permet d'accélérer la convergence du modèle et d'accroître sa capacité à apprendre des relations significatives. L'étude d'ablation menée a confirmé que ces caractéristiques topologiques sont des contributeurs majeurs à la performance prédictive

2.5 Définition de la Variable Cible

La variable cible (la valeur que le modèle doit prédire) a également été redéfinie entre les deux approches, reflétant une compréhension plus fine de la notion de centralité.

1. **Approche Initiale (projet-12):** Cette approche présentait une certaine ambiguïté dans la définition de sa cible. Alors qu'un calcul initial préparait une cible basée sur le logarithme du degré des nœuds, le modèle final a été entraîné pour prédire la **centralité de proximité (closeness centrality)**. Cette dernière, bien qu'utile, est une mesure d'influence moins globale que le PageRank et ce manque de rigueur dans la définition de l'objectif renforce le constat d'une démarche initiale perfectible.
2. **Approche Corrigée (projet-12-1-merged):** La cible a été définie comme le **Z-score du logarithme du PageRank ($\text{zscore}(\log(1 + \text{PageRank}))$)**. Ce choix est méthodologiquement supérieur pour plusieurs raisons. Premièrement, le PageRank est une mesure d'influence plus globale et robuste, capturant l'importance d'un nœud dans l'ensemble du réseau. Deuxièmement, l'application d'une transformation logarithmique permet de compresser la distribution des scores, souvent très asymétrique, la rendant plus apte à une modélisation par régression. Enfin, la standardisation via Z-score normalise la cible, ce qui stabilise et facilite le processus d'apprentissage du modèle.

Une fois les données d'entrée (caractéristiques) et de sortie (cible) correctement préparées et définies, l'étape suivante consiste à construire et comparer les architectures de modèles GNN qui effectueront la tâche de prédiction.

3.0 Architectures des Modèles et Protocole Expérimental

Le choix des Réseaux de Neurones sur Graphes (GNNs) pour cette tâche de prédiction de centralité est motivé par leur capacité à constituer l'état de l'art pour l'apprentissage sur données structurées. Les GNNs excellent à apprendre des représentations de nœuds (*plongements*) en combinant de manière itérative les caractéristiques propres à un nœud avec celles de son voisinage, capturant ainsi simultanément les informations sémantiques et topologiques.

3.1 Architectures des Réseaux de Neurones sur Graphes (GNN)

Trois architectures de GNN populaires ont été testées et comparées dans le cadre de cette étude, chacune avec un mécanisme d'agrégation de voisinage distinct :

- **GCN (Graph Convolutional Network)** : Applique une agrégation de type moyenne pondérée des caractéristiques du voisinage, analogue à une convolution sur graphe.
- **GraphSAGE (Graph Sample and Aggregate)** : Propose un cadre plus général où différentes fonctions d'agrégation (moyenne, max-pooling, etc.) peuvent être utilisées sur un voisinage échantillonné.
- **GAT (Graph Attention Network)** : Utilise des mécanismes d'attention pour pondérer dynamiquement l'importance des voisins lors de l'agrégation, permettant au modèle d'apprendre quels voisins sont les plus pertinents.

L'approche corrigée (projet-12-1-merged) a systématiquement amélioré ces architectures de base par l'ajout de deux couches essentielles :

1. **BatchNorm (Batch Normalization)** : Appliquée après chaque couche de convolution, elle normalise les activations pour stabiliser et accélérer le processus d'entraînement.
2. **Dropout** : Appliquée également entre les couches, elle désactive aléatoirement une fraction des neurones pendant l'entraînement, agissant comme un puissant régularisateur pour prévenir le sur-apprentissage.

3.2 Protocole d'Entraînement et d'Évaluation

Un protocole expérimental rigoureux et commun aux deux études a été mis en place pour garantir une comparaison équitable des modèles.

- **Séparation des données** : Les nœuds du graphe ont été partitionnés en trois ensembles distincts pour l'entraînement (70 %), la validation (15 %) et le test (15 %). Cette séparation au niveau des nœuds garantit que le modèle est évalué sur sa capacité à généraliser à des utilisateurs jamais vus pendant l'entraînement.
- **Optimiseur** : L'optimiseur **Adam** a été utilisé, avec un taux d'apprentissage de 0.01 et une décroissance de poids (régularisation L2) de $1e-4$.
- **Fonction de Perte** : L'**Erreur Quadratique Moyenne (MSE)**, standard pour les tâches de régression, a été utilisée pour quantifier l'écart entre les prédictions et les valeurs réelles.
- **Métriques d'Évaluation** : La performance des modèles a été évaluée à l'aide de trois métriques complémentaires :
 - **RMSE (Root Mean Squared Error)** : L'erreur quadratique moyenne racinée, dans la même unité que la cible.
 - **MAE (Mean Absolute Error)** : L'erreur absolue moyenne, moins sensible aux outliers que la RMSE.
 - **R² (Coefficient de détermination)** : Indique la proportion de la variance de la variable cible qui est prédictible à partir des caractéristiques. Un score de 1.0 indique une prédiction parfaite, tandis qu'un score de 0.0 indique une performance équivalente à un modèle naïf qui prédirait systématiquement la moyenne. Un score négatif signifie que le modèle est moins performant que ce modèle naïf.

La section suivante présente et analyse de manière comparative les résultats de performance obtenus en appliquant ce protocole aux différentes architectures et approches de préparation des données.

4.0 Analyse Comparative des Résultats

Cette section est dédiée à l'analyse comparative des performances des modèles, en se concentrant sur l'évaluation de l'impact des améliorations méthodologiques introduites dans la version projet-12-1-merged par rapport à l'approche initiale projet-12.

4.1 Performance de Prédiction

Les performances finales des trois architectures GNN sur l'ensemble de test sont résumées dans le tableau ci-dessous.

Modèle	Approche	RMSE	MAE	R ²
GCN	Initiale (projet-12)	0.1047	0.0651	0.0069
GraphSAGE	Initiale (projet-12)	0.1068	0.0680	-0.0344F
GAT	Initiale (projet-12)	0.1047	0.0662	0.0060
GCN	Corrigée (projet-12-1-merged)	0.0270	0.0185	0.5983
GraphSAGE	Corrigée (projet-12-1-merged)	0.1548	0.1129	-12.1475
GAT	Corrigée (projet-12-1-merged)	0.0677	0.0564	-1.5158

L'analyse de ces résultats révèle plusieurs points saillants :


1. **Amélioration Spectaculaire du GCN** : Le modèle GCN de l'approche corrigée surpasse très largement toutes les autres configurations. Son score R² passe d'une valeur proche de zéro (0.007), indiquant une absence quasi-totale de pouvoir prédictif, à une valeur de **~0.60**. Cela signifie que le modèle corrigé parvient à expliquer environ 60% de la variance de la centralité PageRank, ce qui représente une performance très significative.
2. **Dégradation des Modèles GraphSAGE et GAT** : De manière surprenante, les modèles GraphSAGE et GAT voient leurs performances s'effondrer dans l'approche corrigée, affichant des scores R² fortement négatifs. Cela suggère une instabilité d'entraînement ou une sensibilité accrue de ces architectures plus complexes aux changements de la distribution des données d'entrée (nouvel encodage, nouvelles caractéristiques, nouvelle cible), les rendant moins performantes qu'un simple modèle de référence.

4.2 Étude d'Ablation des Caractéristiques

Pour comprendre l'importance relative des différents groupes de caractéristiques, une étude d'ablation a été menée sur le meilleur modèle (GCN de l'approche corrigée). Cette étude consiste à entraîner et évaluer le modèle en retirant ou combinant sélectivement certains groupes de caractéristiques.

Configuration	Description	R ²
topo_deg_norm_clust_core	Degré, Clustering et k-core	0.5325
topo_only	Uniquement les 4 caractéristiques topologiques	0.2684
full	Toutes caractéristiques (démographiques + topo)	0.2510
demo_only	Uniquement caractéristiques démographiques	-0.2409
pr_only	Uniquement la caractéristique PageRank	-3.8644
none	Aucune caractéristique nodale (apprentissage structurel pur)	-6.7020

Conclusion de l'étude d'ablation : Premièrement, les caractéristiques topologiques sont **nettement plus prédictives** de la centralité que les caractéristiques démographiques, qui à elles seules dégradent la performance (R² négatif). Deuxièmement, et c'est la conclusion la plus importante, le modèle le plus performant (R² = 0.53) n'est pas celui qui utilise toutes les données (full), mais une sélection judicieuse de caractéristiques topologiques (deg_norm, clust, core). L'ajout des caractéristiques démographiques et de la caractéristique PageRank (pr) – qui est fortement corrélée à la variable cible dérivée du PageRank – introduit en réalité un bruit ou une forme de fuite de données (*target leakage*) qui dégrade la performance. Cela démontre un principe fondamental : l'ingénierie des caractéristiques ne consiste pas seulement à ajouter plus de données, mais à sélectionner les **bonnes** données.



=== Résultats complets de l'ablation ===


	Configuration	Nb_Features	RMSE	MAE	R²
0	topo_deg_norm_clust_core	3	0.0292	0.0132	0.5325
1	topo_only	4	0.0365	0.0165	0.2684
2	full	6	0.0369	0.0251	0.2510
3	topo_clust_core_pr	3	0.0387	0.0208	0.1767
4	topo_deg_norm_core_pr	3	0.0389	0.0181	0.1678
5	core_only	1	0.0475	0.0307	-0.2380
6	demo_only	2	0.0475	0.0244	-0.2409
7	topo_core_pr	2	0.0475	0.0244	-0.2409
8	topo_deg_norm_pr	2	0.0588	0.0160	-0.8959
9	topo_clust_core	2	0.0649	0.0354	-1.3098
10	topo_deg_norm_clust_pr	3	0.0786	0.0344	-2.3955
11	topo_clust_pr	2	0.0897	0.0267	-3.4137
12	pr_only	1	0.0941	0.0312	-3.8644
13	topo_deg_norm_clust	2	0.0997	0.0376	-4.4557
14	none	0	0.1184	0.0664	-6.7020
15	clust_only	1	0.1338	0.0707	-8.8316
16	topo_deg_norm_core	2	0.2053	0.1139	-22.1391
17	deg_norm_only	1	0.3508	0.1205	-66.5515

4.3 Analyse Post-Hoc des Apprentissages

Cette section explore plus en profondeur les propriétés des représentations latentes (*plongements*) apprises par le meilleur modèle (GCN de l'approche projet-12-1-merged) pour mieux comprendre ce que le modèle a réellement appris.

4.3.1 Visualisation des Plongements (Embeddings)

Les plongements de nœuds ont été projetés dans un espace 2D à l'aide des algorithmes t-SNE et UMAP pour une inspection visuelle. Les points ont ensuite été colorés en fonction des attributs des utilisateurs (région, âge). Les visualisations montrent une distribution des points relativement amorphe, **sans formation de clusters clairs ou de structures sémantiques évidentes** basées sur les attributs démographiques. Cela indique que le modèle n'a pas appris à regrouper les utilisateurs en fonction de leur région ou de leur âge, ce qui est cohérent avec le faible pouvoir prédictif de ces variables mis en évidence par l'étude d'ablation.



4.3.2 Test d'Homophilie et Prédiction de Liens

L'homophilie est le principe selon lequel les individus ont tendance à se lier à d'autres qui leur sont similaires. Pour tester si les plongements appris capturent ce signal, ils ont été utilisés pour une tâche de prédiction de liens. Le score **AUC (Area Under the Curve) obtenu est de 0.5000**.

Un score AUC de 0.5 est équivalent à une prédiction effectuée au hasard. Ce résultat démontre que les plongements, bien qu'extrêmement efficaces pour la tâche de prédiction de centralité, **ne contiennent aucune information pertinente pour prédire la formation de liens**. Le modèle a appris à se concentrer sur les signaux structurels d'influence et a ignoré les signaux d'homophilie.

4.3.3 Comparaison des Communautés Structurelles et Sémantiques

Une dernière analyse a comparé les communautés détectées par deux approches :

1. **Structurelle** : L'algorithme de Louvain, qui identifie des groupes de nœuds densément connectés entre eux.
2. **Sémantique** : L'algorithme KMeans appliqué sur les plongements de nœuds appris par le GNN.

La similarité entre ces deux partitions a été mesurée à l'aide du **NMI (Normalized Mutual Information)**, qui a donné un score très faible de **0.003**. Ce résultat confirme une décorrélation quasi

totale entre les communautés structurelles denses du réseau et les groupes sémantiques formés par le modèle pour la tâche de prédiction de centralité.

5.0 Discussion et Conclusion

Cette étude a démontré avec succès la capacité des modèles GNN à prédire une mesure de centralité complexe sur un sous-graphe du réseau social Pokec. Plus important encore, l'analyse comparative des deux approches expérimentales a permis de tirer des enseignements méthodologiques cruciaux sur les facteurs qui conditionnent la performance de ces modèles.

5.1 Synthèse des Apports Méthodologiques

Les conclusions méthodologiques clés de cette étude comparative peuvent être résumées comme suit :

- **Impact de l'encodage des données** : Le passage d'un LabelEncoder inapproprié à un OneHotEncoder pour les variables catégorielles nominales a été un facteur déterminant dans l'amélioration drastique des performances (R^2 passant de ~ 0.01 à ~ 0.60). Cela confirme que le respect des propriétés mathématiques des données est une condition non négociable pour un apprentissage réussi.
- **Importance de l'ingénierie des caractéristiques** : L'étude d'ablation a prouvé que les caractéristiques topologiques (degré, clustering, k-core) sont les prédicteurs dominants de la centralité PageRank. De plus, elle a montré que la sélection de caractéristiques pertinentes est plus impactante que l'ajout brut de toutes les données disponibles, qui peut introduire du bruit et dégrader la performance.
- **Performance des architectures GNN** : Pour cette tâche de régression nodale, l'architecture GCN, plus simple, s'est avérée non seulement la plus performante mais aussi la plus stable. L'ajout de couches de BatchNorm et Dropout a été essentiel pour stabiliser l'entraînement et permettre au modèle d'atteindre son plein potentiel.

5.2 Interprétation des Limites

L'analyse post-hoc a révélé une limite fondamentale des représentations apprises : leur **spécialisation extrême**. Les plongements, optimisés pour prédire la centralité, se sont montrés totalement inefficaces pour des tâches alternatives comme la prédiction de liens (AUC de 0.5) ou la détection de communautés structurelles (NMI de 0.003).

Cette observation n'est pas un échec, mais une illustration du principe de spécialisation des modèles d'apprentissage profond. Pour exceller dans la prédiction de la centralité (une mesure d'influence globale), le modèle a appris à distiller les signaux topologiques liés au rôle et à la position d'un nœud dans le graphe, tout en apprenant à ignorer activement d'autres signaux structurels comme l'homophilie (similarité locale) qui agissent comme du bruit pour sa tâche spécifique. Cela implique que des plongements appris pour une tâche ne sont pas nécessairement transférables à une autre, même sur le même graphe.

5.3 Conclusion Générale

En conclusion, l'expérimentation projet-12-1-merged a réussi à construire un modèle GNN performant et robuste pour la prédiction de la centralité PageRank sur le réseau Pokec. Cette étude démontre de manière empirique la très grande sensibilité des modèles GNN aux choix de prétraitement, d'encodage et d'ingénierie des caractéristiques. Elle illustre également de façon saisissante comment les GNNs apprennent des représentations de nœuds hautement spécialisées, optimisées pour la tâche pour laquelle ils sont entraînés, soulignant l'importance d'aligner l'architecture du modèle, les données d'entrée et l'objectif de la tâche pour obtenir des résultats significatifs et fiables.